

Modelos de Regresión

– Fundamentos–

Juan Carlos Martínez Ovando
`juan.martinez.ovando@itam.mx`

20 de octubre de 2015

1. Modelos lineales Fundamentos

y - variable aleatoria

F - función de distribución para y

\mathbb{E}_F - esperanza, con respecto a la distribución F , i.e.

$$\mathbb{E}_F(y) = \int yF(dy)$$

x - variable explicativa para y , tal que

$$\mathbb{E}_F(y|x) = \alpha + \beta x,$$

ó

$$y = \alpha + \beta x + \varepsilon,$$

con

$$\varepsilon \sim G$$

tal que

$$\mathbb{E}_G(\varepsilon) = 0$$

1. Modelos lineales Fundamentos

¿Quién es F en la relación anterior?

$F|x$ - es en realidad la distribución de probabilidad G desplazada por $\alpha + \beta x$, i.e.

$$F(y|x) = G(y - \alpha - \beta x)$$

Entonces, en realidad estamos interesados en $F(y|x)$ y, sobre todo, en $\mathbb{E}_F(y|x)$ cuando estudiamos los modelos de regresión.

1. Modelos lineales Fundamentos

¿Qué un modelo lineal?

Re: Es un modelo que relaciona la esperanza condicional de y con x en la media, i.e.

$$\mathbb{E}_F(y|x) = g(x, \theta, \varepsilon),$$

θ es un conjunto de parámetros [e.j., $\theta = (\alpha, \beta)$]

ε es una innovación aleatoria $\varepsilon \sim G$, t.q. $\mathbb{E}_G(\varepsilon) = 0$

g es una función lineal en la innovación y los parámetros, pero multiplicativa en x respecto a los parámetros

1. Modelos lineales Fundamentos

Ejemplos de modelos lineales:

- $g(x, \theta, \varepsilon) = \alpha + \beta x$
- $g(x, \theta, \varepsilon) = \alpha + \beta \log(x)$
- $g(x, \theta, \varepsilon) = \alpha + \beta \log(x) + \gamma x^2$
- $g(x, \theta, \varepsilon) = \alpha + \beta \log(x) + \sum_{j=1}^J \gamma_j \psi(x, \eta_j)$

1. Modelos lineales Fundamentos

Ejemplos de modelos no lineales:

- $g(x, \theta, \varepsilon) = \alpha \cdot x^\beta$
- $g(x, \theta, \varepsilon) = \alpha \cdot x^\beta$
- $g(x, \theta, \varepsilon) = \alpha + \log(\beta x) + \gamma x^2$

1. Modelos lineales Fundamentos

Regresión lineal múltiple

- $g(x, \theta, \varepsilon) = \alpha + \beta_1 x_1 + \dots + \beta_p x_p,$

Alternativamente,

- $g(x, \theta, \varepsilon) = \theta' x,$

$$x = (1, x_1, \dots, x_p)'$$

$$\theta = (\alpha, \beta_1, \dots, \beta_p)'$$

1. Modelos lineales Fundamentos

Inferencia

- $g(x_i, \theta, \varepsilon_i) = \theta' x_i$, para $i = 1, \dots, n$, ó

$$y_i = \theta' x_i + \varepsilon_i,$$

$$x_i = (1, x_{1,i}, \dots, x_{p,i})'$$

$$\theta = (\alpha, \beta_1, \dots, \beta_p)'$$

$$\varepsilon_i \stackrel{iid}{\sim} G$$

La inferencia sobre los modelos lineales descansa fundamentalmente sobre ideas de álgebra lineal y matricial. Así, revisémos algunos conceptos y propiedades útiles.

1. Modelos lineales Fundamentos

Algebra matricial: Notación

A - matriz con elementos (a_{ij})

I - matriz identidad, i.e. $a_{ij} = 1$, si $i = j$, y 0, e.o.c.

0 - matriz nula, i.e. $a_{ij} = 0$

A' - transpuesta de la matriz A

A^{-1} - inversa de la matriz, t.q. $AA^{-1} = I$

1. Modelos lineales Fundamentos

Algebra matricial: Operadores. Sean $A = (a_{ij})$ y $B = (b_{ij})$,

■

$$A + B = (a_{ij} + b_{ij}),$$

iff $\dim(A) = \dim(B)$

■

$$A \cdot B = \left(\sum_k a_{ik} b_{kj} \right),$$

iff $\text{ncol}(A) = \text{nrow}(B)$

1. Modelos lineales Fundamentos

Algebra matricial: Propiedades.

■

$$(A')^{-1} = (A^{-1})',$$

iff A es no singular

■

$$(A \cdot B)' = B' \cdot A'$$

■

$$(A \cdot B)^{-1} = B^{-1} \cdot A^{-1}$$

iff A y B son no singulares

■

$$\text{rank}(AA') = \text{rank}(A'A) = \text{rank}(A)$$

- Si x y y son dos vectores, y A es no singular, entonces

$$x = A \cdot y \quad \text{y} \quad A^{-1} \cdot x = y$$

son equivalentes.

1. Modelos lineales Fundamentos

Algebra matricial: Formas cuadráticas.

y - vector de dimensión $n \times 1$

A - matriz de dimensión $n \times n$

- La forma cuadrática de y y A es

$$y' \cdot A \cdot y = \sum_i \sum_j y_i a_{ij} y_j.$$

■

$$\text{rank}(\mathbf{y}' \cdot \mathbf{A} \cdot \mathbf{y}) = \text{rank}(\mathbf{A})$$

- $\mathbf{y}' \cdot \mathbf{A} \cdot \mathbf{y}$ es *definida positiva* si $\mathbf{y}' \cdot \mathbf{A} \cdot \mathbf{y} > 0$ para todo \mathbf{y} no nulo.
- Si \mathbf{A} es t.q. $\mathbf{A}'\mathbf{A} = \mathbf{I}$, se dice que \mathbf{A} es *ortogonal*.

1. Modelos lineales Fundamentos

Algebra matricial: Transformaciones y formas cuadráticas.

y - vector de dimensión $n \times 1$

x - vector de dimensión $p \times 1$

P - matriz de dimensión $n \times p$

■ t.q.

$$y = Px.$$

Entonces,

-

$$y' Ay = x' P' AP x = x' B x,$$

con $B = P' AP$, y B es no singular.

Teoremas útiles:

- Si P es no singular y A es definida positiva, entonces $P' AP$ es definida positiva.
- A , matriz simétrica, es definida positiva iff existe P no singular, t.q.

$$A = PP'.$$

1. Modelos lineales Fundamentos

Determinantes:

A - matriz simétrica de dimensión $p \times p$

- **Raíz característica:** λ escalar, tal que

$$Ax = \lambda x,$$

para todo vector x .

x - vector $(p \times 1)$ característico asociado a λ .

- **Polinomio característico:** Se define como,

$$|\mathbf{A} - \lambda \mathbf{I}|,$$

que es de orden p .

- *Las raíces del polinomio característico corresponden a las raíces características de \mathbf{A} .*

1. Modelos lineales Fundamentos

Determinantes (algunos teoremas)

- $\text{rank}(A) =$ número de raíces unitarias distintas de 0
- Si C es una matriz ortogonal, entonces las raíces características de A y CAC'
- Si A es simétrica, entonces sus raíces características son reales.
- Si A es simétrica, existe una matriz ortogonal C , t.q.

$$C'AC = D,$$

donde \mathbf{D} es una matriz diagonal cuyas entradas son las raíces características de \mathbf{A} .

- Si \mathbf{C} es una matriz ortogonal, entonces

$$|\mathbf{C}'\mathbf{A}\mathbf{C}| = |\mathbf{A}|.$$

- Si \mathbf{A} es singular, entonces $|\mathbf{A}| = 0$.
- Si \mathbf{C} es ortogonal, entonces $|\mathbf{C}| = \pm 1$.

1. Modelos lineales Fundamentos

Traza: La traza de una matriz se define como $tr(\mathbf{A}) = \sum_{j=1}^p a_{jj}$.

- $tr(\mathbf{I}) = p$.
- $tr(\mathbf{AB}) = tr(\mathbf{BA})$.
- $tr(\mathbf{ABC}) = tr(\mathbf{CAB}) = tr(\mathbf{BCA})$.
- Si \mathbf{C} es ortogonal, entonces $tr(\mathbf{C}'\mathbf{A}\mathbf{C}) = tr(\mathbf{A})$.

1. Modelos lineales Fundamentos

Lo que sigue:

- *Encontrar distribuciones de probabilidad asociadas a formas cuadráticas de matrices.*
- *Deducir derivadas de formas cuadráticas (para la estimación por máxima verosimilitud).*

1. Modelos lineales Inferencia

$\{y_i, \mathbf{x}_i\}$ - colección de n variables y covariables

y_i - variable de respuesta de la i ésima observación

$\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ conjunto de p covariables de la i -ésima observación

Relación lineal:

$$\mathbb{E}(y_i) = \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

1. Modelos lineales Inferencia

Alternativamente:

$$\begin{aligned} y_i &= \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \\ \varepsilon_i &\stackrel{iid}{\sim} G, \end{aligned}$$

t.q.

$$\mathbb{E}_G(\varepsilon_i) = 0.$$

1. Modelos lineales Inferencia

Representación matricial:

$$y = X\beta + \varepsilon,$$

donde

- $y = (y_1, \dots, y_n)'$
- $X = (x_1, \dots, x_n)'$
- $\beta = (\beta_1, \dots, \beta_p)'$
- $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)'$

1. Modelos lineales Inferencia

Pregunta: ¿Qué podemos decir acerca de β ?

Alternativas:

- Método de momentos*
- Estimación por máxima verosimilitud*
- Mínimos cuadrados*
- Inferencia bayesiana

1. Modelos lineales Inferencia

Método de momentos (MdeM). Supuestos:

- Las observaciones son *iid*
- No forma distribucional es supuesta para F , sólo los momentos poblacionales (o del modelo),

$$M(k) = \mathbb{E}_F(y^k | \mathbf{x}),$$

son requeridos.

Recordemos que $F(y|\mathbf{x})$ es en realidad lo que deseamos encontrar.

Procedimiento:

Supongamos que $\theta = (\theta_1, \dots, \theta_k)$ caracterizan a $F(y_i|x_i, \theta)$.

- Dada la muestra con n observaciones, el MdeM consiste en empatar los momentos muestrales con los momentos poblacionales (del modelo), los cuales dependen de θ , y resolver las ecuaciones resultantes para θ (simultáneamente) .

1. Modelos lineales Inferencia

Máxima verosimilitud (MV). Supuestos:

- Las observaciones son *iid*
- Se supone una forma distribucional para F –usualmente gaussiana– siendo $f(y|x, \theta)$ la densidad.
- Función de verosimilitud,

$$lik(\theta, \text{datos}) = \prod_{i=1}^n f(y_i|x_i, \theta)$$

Procedimiento:

- El estimador de θ , denotado por $\hat{\theta}$, se obtiene como

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} \operatorname{lik}(\theta, \text{datos}).$$

- La solución, calcular y resolver para θ ,

$$\frac{\partial}{\partial \theta} \operatorname{lik}(\theta, \text{datos}) = 0.$$

1. Modelos lineales Inferencia

Mínios cuadrados (MC). Supuestos:

- Las observaciones son *iid*
- No se supone una forma distribucional para F , solo se requiere la restricción $\mathbb{E}_G(\varepsilon_i) = 0$.
- Función de cuadrados de los residuos,

$$rss(\beta, \text{datos}) = \sum_{i=1}^n r_i^2 = \sum_{i=1}^n (y_i - \mathbf{x}_i' \hat{\beta})^2,$$

para el estiador $\hat{\beta}$ objetivo.

- ¿Qué pasa con el estimador de dispersión de ε ?

Procedimiento:

- El estimador de β , denotado por $\hat{\beta}$, se obtiene como

$$\hat{\beta} = \operatorname{argmin}_{\beta \in \mathcal{R}} \operatorname{rss}(\beta, \text{datos}).$$

1. Modelos lineales Inferencia

Desviaciones.

- Todos los procedimientos se basan, de alguna forma, en la noción de *desviaciones*. Desviaciones de los datos de respuesta observados (y_i) y de los datos “ajustados”, (\hat{y}_i), donde

$$\begin{aligned}\hat{y}_i &= \mathbf{x}_i' \hat{\boldsymbol{\beta}}. \\ &= \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_p x_{ip}.\end{aligned}$$

1. Modelos lineales Inferencia

Desviaciones.

Desviaciones.jpg

1. Modelos lineales Inferencia

Desviaciones.

- Debemos considerar que la relación entre y y x (inclusive en el caso en que sólo tengamos una sola covariable x) no es simétrica.
- Los residuos cuya suma de cuadrados deseamos minimizar se refieren a las desviaciones verticales.

1. Modelos lineales Inferencia

Supuestos adicionales.

- Los datos observados son observados aleatoriamente.
- Las columnas en \mathbf{X} no son colineales (o al menos, no estrictamente colineales, admitiendo cierto grado de colinealidad.)
- Las observaciones en (y_i) son obtenidas con precisión de medición.
- Los residuos (r_i) tienen varianza constante en i y una distribución normal (o gaussiana).

1. Modelos lineales Predicción

- Los modelos estadísticos se emplean, comúnmente para predicción o pronóstico.
- Aun cuando β sea el interés final, la capacidad predictiva del modelo le da validez a los resultados.
- Predicción en modelos lineales es relativamente simple.

1. Modelos lineales Predicción

Procedimiento predictivo:

1. Definimos el modelo

$$y = x'\beta + \varepsilon.$$

2. Estimamos $\hat{\beta}$ y $\hat{\sigma}$.

3. Obtenemos el modelo ajustado

$$\hat{y} = x'\hat{\beta}.$$

4. Predecimos un valor futuro

$$\hat{y}_f = x'_f \hat{\beta},$$

con base en covariables futuras x_f .

1. Modelos lineales Predicción

Precisión de las predicciones:

- Intervalos de predicción para

$$\hat{y}_f \in \mathbf{x}'_f \hat{\boldsymbol{\beta}} \pm \rho \hat{\sigma},$$

con base en covariables futuras \mathbf{x}_f y en $\hat{\sigma}$. El parámetro ρ se fija para un cierto grado de credibilidad.

- Más aun, podemos recuperar la distribución predictiva

$$F(y_f | \mathbf{x}_f) = N(y_f | \mathbf{x}'_f \hat{\boldsymbol{\beta}}, \hat{\sigma}^2).$$